

Projektni zadatak

Predmet: Inteligentni sistemi

Tema: OCR - Optical Character Recognition

Anja Stojković

Milana Tošić

1. Uvod

1.1 Cilj projekta

Cilj projekta je razvoj sistema za automatsko prepoznavanje teksta na slikama komunalnih računa. Projekat se sastoji iz dva dela. U prvom delu je iskorišćen YOLO model, koji je istreniran da na određenim računima pronalazi tekst koji će dalje biti poslat u drugi i glavni deo projekta. Drugi deo projekta je komponenta za prepoznavanje teksta sa računa, koja je realizovana primenom neuronskih mreža - konkretno primenom CRNN arhitekture u kombinaciji sa CTC loss funkcijom.

1.2 Opis problema

Slike računa slikane mobilnim telefon pod realnim uslovima, unose šum, poput različitog i neravnomernog osvetljenja, senke, zamućenja. Takođe papiri od računa nisu idealno ravni, neki su presavijeni i izgužvani. Sve ovo zajedno daju poteškoću modelu u prepoznavanju karaktera sa njih. Pored navedenog, računi se sastoje od latiničnog i ćiriličnog teksta, što znači da model treba da nauči da raspozna oba pisma. Još jednu poteškoću čine i različiti fontovi na računima.

2. Analiza problema

2.1 Opis ulaznih podataka i anotacija

Ulazni podaci čine slike računa koje su slikane mobilnim telefonom u različitim uslovima. Slike su raspodeljene u sedam kategorija: struja, uplatnica, smeće, održavanje zgrade, mts, jotel i grejanje. Ukupno, dataset čini 166 slika, odnosno 1477 cropova. Računi koji sadrže ćirilični tekst: jotel (5 računa), održavanje zgrade (15 računa), struja (78 računa) i na uplatnicama je bilo delom ćiriličnog teksta, a delom latinice. Ostale kategorije su činile latinični tekst. Realne slike su raspoređene u train, validation i test skup, tako da je ćirilični tekst bio zastupljen i u validation i u test skupu oko 50%.

Prikaz raspodele računa po grupama:

grejanje	10 train	2 validation	2 test
jotel	3 train	1 validation	1 test
mts	13 train	2 validation	3 test

održavanje zgrade	11 train	2 validation	2 test
smeće	9 train	1 validation	2 test
struja	63 train	8 validation	7 test
uplatnica	18 train	3 validation	3 test

KONAČNA RASPODELA (croppova):

TRAIN: 1110 (75.2%)

VAL: 182 (12.3%)

ćirilični: 94 (51.6%)

TEST: 185 (12.5%)

ćirilični: 90 (48.6%)

Anotacija se vršila preko Streamlit aplikacije, preko koje je svaki detektovan region za čitanje teksta, ručno cropovan u redove, koji su sadržali ili više reči u jednom redu ili po jednu reč.

2.2 Sintetički dataset

Zbog male zastupljenosti ćiriličnog pisma u dataset-u sa realnim slikama, generisane su sintetičke slike - cropovi teksta. Sintetičke slike su generisane pomoću biblioteke Pillow za renderovanje teksta i OpenCV za dodavanje realističnog šuma. Tekst je renderovan na različitim pozadinama sa različitim fontovima. Na svaku sliku su primenjene nasumične transformacije: rotacija, perspektivno izobličenje, Gausov šum, zamućenje, erozija i dilatacija, senka skenera i JPEG kompresija.

Sintetičke slike su raspoređene u kategorije tako da je najviše bilo u onim kategorijama koje je model teško prepoznavao. Dodata je i kategorija floor, koja je povećavala zastupljenost retkih karaktera do minimalnog praga od 60. Sintetički dataset je činio ukupno 1654 slike koje su spojene sa train splitom.

Rasodela sintetički generisanih slika:

ćirilični dugi tekst	200
ćirilični kratki tekst	400
brojevi	300
latinica	100
floor(retki karakteri)	654

3. Arhitektura sistema

3.1 Prepoznavanje teksta - CRNN arhitektura + CTC Loss

3.1.1 CRNN arhitektura

Za prepoznavanje teksta sa slike korišćenja je CRNN arhitektura - CNN + BiLSTM. CNN (Convolutional Neural Network) je neuronska mreža koja je inspirisana načinom kako funkcioniše ljudski vid. Najčešće se koristi za analizu vizuelnih i prostornih podataka. Dizajnirana je da efikasno prepozna je objekte i oblike.

Mreža prima slike fiksne visine od 48px i promenljive širine, slike se padduju na dužinu od 768 px. Ulazna slika prolazi kroz niz konvolucija, batch normalizacija i pooling operacija. Konkretno u mreži imamo šest konvolutivnih slojeva u četiri bloka. Ulazni kernel je 3X3 piksela, stride = 1, što znači da se pomeramo za samo jedan piksel i korišćen je padding tako da ulazna karakteristika ima isto piksela kao i izlazna. Max pooling sloj je smanjivao visinu slike, tako da je na kraju visina bila 3px. Prva dva puta je smanjena i širina slike.

konvolucionni sloj	izlazni kanal	max pooling
Conv1	32	24
Conv2	64	12
Conv3	128	12
Conv4	128	6
Conv5	256	6
Conv6	256	3

Na izlazu iz CNN, tenzor oblika [B, 256, 3, 192] transformiše se permutacijom i flatten operacijom u sekvencu oblika [B, 192, 768], gde svaki od 192 vremenska koraka odgovara jednoj koloni piksela originalne slike i koji su nam bitni za BiLSTM, a dimenzija 768 predstavlja spojene karakteristike svih kanala i preostalih visina.

BiLSTM (Bidirectional Long - Short Term Memory) obrađuje podatke u oba smera. Čitanjem podataka sa leva na desno i sa desna na levo model zna i prošli i budući kontekst. BiLSTM kod OCR-a čita trake, koje predstavljaju vremenske korake.

Sekvenca oblika [T, B, 256] ulazi u bidirekcioni LSTM sloj, sa 256 skrivenih jedinica po smeru i dva LSTM sloja. Izlaz iz LSTM sloja ima dimenziju 512 po vremenskom koraku.

Na kraju, izlazni linearni sloj mapira vektor od 512 dimenzija u prostor od 156 klasa. Klase predstavljaju latinična, ćirilčna slova, specijalne karaktere i blank karakter. Izlaz modela je tenzor oblika [T, B, 156] koji se koristi kao ulaz za CTC loss funkciju tokom treninga.

3.1.2 CTC loss

CTC (Connections Temporal Classification) loss funkcija služi za obučavanje modela gde dužina ulaznih podataka ne odgovara dužini izlaznih podataka i gde precizno vremensko poravnanje nije poznato. Problemi koje CTC loss rečava su: različite dužine sekvenci, nepoznato poravnanje, dvostruka predikcija. Funkcija uvodi blank token i primenjuje jednostavna pravila transformacije na izlaznu matricu verovatnoća modela (spajanje duplikata i uklanjanje praznih tokena).

Ukupna verovatnoća tačne transkripcije Y računa se sabiranjem verovatnoća svih mogućih staza (putanja) koje se mogu svesti na tu transkripciju. Funkcija gubitka se zatim definiše kao negativni logaritam verovatnoće te ciljne sekvence:

$$L = -\ln P(Y|X)$$

Nakon BiLSTM sloja, pošto ide u oba smere koji se spajaju, često dobijamo karaktere koji su duplirani, CTC rešava ovaj problem.

Za dekodiranje tokom evaluacije koristi se greedy pristup: za svaki vremenski korak se bira karakter sa najvećom verovatnoćom. Iz dobijene sekvence se zatim uklanjaju uzastopna ponavljanja istog karaktera i svi blank tokeni, čime se dobija konačna predikcija.

4. Implementacija

4.1 Augmentacija podataka

Na train skupu je odrađena augmentacija podataka, radi povećanja raznovrsnosti podataka i smanjenja overfitting-a. Primenjene su sledeće transformacije: rotacija, perspektivno izobličenje, kontrast i osvetljenje, gausovo zamućenje, Gausov šum, erozija ili dilatacija i JPEG kompresija.

4.2 Postupak treninga

Korišćen je AdamW optimizator, sa početnom stopom učenja od $3e-4$ i weight decay regularizacijom vrednosti $5e-4$. Za menjanje koraka učenja korišćen je CosineAnnealingLR scheduler koji postepeno smanjuje korak učenja tokom 200 epoha. Za rano zaustavljenje korišćen je early stopping, tako što se posmatrala vrednost validacionog gubitka, sa patience = 40. Za best model parametre uzimane su vrednosti gde je CER (Character Error Rate) bio najmanji.

5. Rezultati

5.1 Metrike evaluacije

Primarna metrika - **CER** (Character Error Rate). CER je metrika koja meri tačnost sistema za prepoznavanje teksta. računa procenat pogrešno prepoznatih karaktera upoređivanjem sa tačnim tekstom. CER meri minimalan broj izmena potrebnih da se generisani tekst pretvori u tačan tekst. Računa se na osnovu Lavenštajnovog rastojanja.

Tri vrste grešaka koje se računaju:

1. Zamene (S - Substitutions) - pogrešni karakteri na mestu tačnih

2. Brisana (D - Deletions) - karakteri koji nedostaju
3. Umetanja (I - Insertions) - karakteri viška

Formula za CER:

$CER = (S + D + I) / N$, gde je N ukupan broj karaktera u tačnom tekstu.

Sekundarna metrika - **WER** (Word Error Rate). Za razliku od CER-a WER računa uspešnost sistema na nivou celih reči. Takođe se računa na osnovu Lavenštajnovog rastojanja.

Formula za WER:

$WER = (S+D+I) / N$


N - broj reči u tačnom tekstu,

S - broj reči koje su pogrešno prepoznate i zamenjene drugim rečima,

D - broj reči koje nedostaju,

I - broj reči koje su dodate i ne postoje u originalnom tekstu.

5.2 Rezultati treninga



Na prvoj slici je prikazana kriva učenja modela na train i validation skupu kroz epohe, sa koje možemo zaključiti da je model kontinuirano učio tokom epoha.

Druga slika prikazuje kako se CER menjao kroz epohe na validacionom skupu. Sa nje možemo primetiti kako je model u prvim epohama nasumično nagađao reči i ništa nije pogađao, što nam govori visok CER, dok je u poslednjim epohama CER značajno opao.

5.3 Rezultati na test skupu


Metrike evaluacije na test skupu:

CRNN MODEL				
Slika:	185			
Prosečan CER:	0.0489	(4.89%)		
Prosečan WER:	0.1842	(18.42%)		
Tačno (100%):	125/185	(67.57%)		


— PO GRUPI —				
	broj	CER	WER	tacno
grupa				
grejanje	11	0.0558	0.2741	5
jotel	6	0.0000	0.0000	6
mts	19	0.0129	0.0388	17
odrzavanje_zgrade	16	0.0636	0.1659	7
smece	11	0.0097	0.0455	7
struja	83	0.0699	0.2510	52
uplatnica	39	0.0324	0.1624	31

— PO PISMU —				
	broj	CER	WER	tacno
script				
cyr	59	0.0277	0.1350	44
lat	69	0.0464	0.1484	43
mixed	16	0.0146	0.1168	11
other	41	0.0971	0.3415	27


Sa slike vidimo da je model uspeo da postigne CER od 4.89%. WER je viši, ali to je i očekivano. Primećujemo da je nakon dodavanja više sintetičkih slika sa ćirilničnim tekstom model počeo bolje da generalizuje ćirilčni tekst od latiničnog, dok smo pre imali suprotan slučaj.




Na ovim slikama možemo videti za koliko je uzoraka bila određena vrednost CER-a i WER-a.




Ovde vidimo distribuciju CER-a po grupama računa. Sa slike možemo zaključiti da je model imao najveće vrednosti CER-a uglavnom za grupe struja, uplatnica - u ovoj grupi ima dosta slika gde je mešan ćirilčni i latinični tekst, održavanje zgrade i grajanje. Primećujemo da je CER dosta visok za grupe računa koje imaju više realnih slika. U sintetički generisan dataset je dodato dosta labela sličnih onima iz grupe struja, pošto je model u početku dosta lošije od prikazanih rezultata generalizovao ovu grupu.




Prikaz CER-a i WER-a po pismu. Nakon dodavanja sintetičkog teksta, model više greši na latiničnom pismu. Kategorija other predstavlja brojeve, uočeno je da model ne generalizuje dobro ni njih, pošto čine jako mali deo dataset-a sa realnim slikama. Kako bismo postigle bolje rezultate na prepoznavanju brojeva, sintetički smo generisale i njih, ali je model i dalje grešio dosta kada su u pitanju brojevi.



Sa ove slike vidimo da je model uglavnom imao visok CER za kratak tekst. U sintetički generisan dataset su namerno dodavani primeri kratkih labela, sličnih onima iz grupa na kojima je model imao dosta visok nivo greške na kraćem tekstu.



Nakon što smo analizirale koji karakteri imaju najveću grešku, pokušale smo sa dodavanjem teksta sa tim karakterima u sintetički generisane labela, ali nisu dobijeni bolji rezultati, tako da su labela uklonjene.



Ovde vidimo još neke analize tačnosti po kategorijam.

5.4 Analiza grešaka

Primećujemo da model dosta greši u prepoznavanju brojeva, kao i specijalnih karaktera, koji čine mali deo realnih slika. Pokušano je sa dodavanjem sličnih labela u sintetički generisan dataset. Takođe model na nekim primerima pogreši latinični i ćirilični tekst, primer je Износ i Изп, gde je model zamenio ćirilično n sa latiničnim. Slike su dosta lošeg kvaliteta, koji sintetički generisan dataset ne može da postigne i nakon svih urađenih augmentacija.

Primeri najgorih predikcija:

tacno	predviđeno
679	078
(kW/kWh)	JkWh-
11.04	164
Износ	Изпо
=4.900,00	=4-800.00
POREZ NA IMOVINU	POREZ NA RONNU
(динара)	(инауа
1.311,72	13172
4,2580	12580
103	10
247	J47
Šifra Naziv artikla kod JM KOL PDV Rabat	Šifra Naziv artkaa Mo JM KOi Cposa Ratn
3608,39	3,608.39
174 kWh	174ИWh
Црвена зона	Цправа зона

Tačno: 11.04 | Predviđeno: 164 | CER: 0.600 | Grupa: struja




Tačno: 679 | Predviđeno: 078 | CER: 0.667 | Grupa: struja




Tačno: (kW/kWh) | Predviđeno: JkWh- | CER: 0.625 | Grupa: struja



Tačno: 96 | Predviđeno: 95 | CER: 0.500 | Grupa: struja



Tačno: иници | Predviđeno: 8ици | CER: 0.400 | Grupa: struja



6. Zaključak

Model za prepoznavanje karaktera je uspeo uspešno da prepoza tekst na više od polovine slika, ali i dalje ima nedostatke na kojima treba poraditi, poput boljeg prepoznavanja latiničnog teksta, brojeva, specijalnih karaktera. Kako bismo unapredile projekat verujemo da bi najbolje bilo da se doda još slika u dataset, jer se sintetički generisanim slikama ne može postići realističan šum koji pravi izazov modelu u prepoznavanju karaktera. Verujemo da bi ovo pomoglo u boljem prepoznavanju modela bez menjanja arhitekture modela.